

ANALISIS KOMPARATIF YOLOV8 NANO DAN YOLO11 NANO DALAM KLASIFIKASI PENYAKIT DAUN TOMAT BERBASIS PERANGKAT EDGE

SKRIPSI

Diajukan Sebagai Salah Satu Syarat
Untuk Kelulusan Program Sarjana S1
Program Studi Teknik Informatika



Oleh:

Nama : HAYTSAM ADZKA MAWLA

NIM : 43A87006220028

**FAKULTAS TEKNOLOGI INFORMASI DAN DIGITAL
UNIVERSITAS BANI SALEH
BEKASI
2026**

**ANALISIS KOMPARATIF YOLOV8 NANO DAN
YOLO11 NANO DALAM KLASIFIKASI
PENYAKIT DAUN TOMAT BERBASIS
PERANGKAT EDGE**

PROPOSAL SKRIPSI

Diajukan kepada Fakultas Teknologi Informasi dan Digital Universitas Bani Saleh
Sebagai Syarat Untuk Pengajuan Tugas Akhir Pada Program Studi Teknik
Informatika

Oleh:

Haytsam Adzka Mawla

43A87006220028

Pembimbing:

Muhammad Nur, S.Kom., M.Kom.

**PRODI SARJANA TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI DAN DIGITAL
UNIVERSITAS BANI SALEH
2026**

LEMBAR PERSETUJUAN SKRIPSI

Telah diperiksa dan disetujui oleh pembimbing untuk disidangkan pada Sidang Skripsi Program Sarjana (S1), Program Studi **Teknik Informatika** Fakultas Teknologi Informasi dan Digital Universitas Bani Saleh skripsi dengan judul:

ANALISIS KOMPARATIF YOLOV8 NANO DAN YOLO11 NANO DALAM KLASIFIKASI PENYAKIT DAUN TOMAT BERBASIS PERANGKAT EDGE

Bekasi, 06 Juni 2025

Pembimbing Utama

Pembimbing Pendamping

(Muhammad Nur, S.Kom., M.Kom.)

(Marhakim, S.Pd., MM.)

Mengetahui:

Ketua Program Studi **Teknik Informatika**

(Mami Maryati, S.Kom., M.M.S.I.)

DAFTAR ISI

HALAMAN SAMPUL	i
LEMBAR PERSETUJUAN SKRIPSI	ii
DAFTAR ISI	iii
DAFTAR GAMBAR	iv
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang Masalah	1
1.2 Permasalahan Penelitian	3
1.2.1 Identifikasi Masalah	3
1.2.2 Batasan Masalah	4
1.2.3 Rumusan Masalah	5
1.3 Tujuan dan Manfaat Penelitian	5
1.3.1 Tujuan	5
1.3.2 Manfaat	6
1.4 Sistematika Penulisan	7
BAB 2 LANDASAN TEORI DAN KERANGKA PEMIKIRAN	8
2.1 Tinjauan Pustaka	8
2.2 Landasan Teori	10
2.2.1 Penyakit Daun Tomat	11
2.2.2 Klasifikasi Citra	11
2.2.3 <i>Deep Learning</i> dan CNN	12
2.2.4 Keluarga Model YOLO	12
2.2.5 Perangkat <i>Edge</i>	13
2.2.6 Akuisisi Citra dan Faktor Kamera	14
2.2.7 Akurasi dan Efisiensi sebagai Dasar Evaluasi	14
2.3 Kerangka Pemikiran	15
2.4 Kerangka Pemikiran	17
DAFTAR PUSTAKA	18

DAFTAR GAMBAR

Gambar 2.1	Kerangka Pemikiran	17
------------	--------------------------	----

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Tanaman tomat merupakan salah satu komoditas hortikultura yang banyak dibudidayakan dan memiliki nilai ekonomi penting. Namun, produktivitas tomat sering menurun akibat serangan penyakit pada daun, seperti *early blight*, *late blight*, *leaf mold*, *bacterial spot*, dan beberapa penyakit lain yang menimbulkan perubahan warna, bercak, atau kerusakan jaringan daun. Deteksi penyakit daun tomat yang terlambat dapat menyebabkan penurunan kualitas hasil panen, peningkatan kerugian ekonomi, dan keterlambatan penanganan di lapangan Das et al. (2025); Jelali et al. (2024); Nyawose et al. (2025).

Pada praktik konvensional, identifikasi penyakit tanaman masih banyak mengandalkan pengamatan manual oleh petani atau tenaga ahli. Pendekatan ini memiliki keterbatasan karena membutuhkan pengalaman, waktu, serta konsistensi pengamatan yang baik. Dalam kondisi lapangan yang luas dan berubah-ubah, identifikasi manual juga berisiko menimbulkan kesalahan interpretasi, terutama ketika gejala beberapa penyakit tampak mirip secara visual. Oleh karena itu, dibutuhkan pendekatan otomatis yang mampu membantu proses klasifikasi penyakit daun tomat secara lebih cepat dan konsisten Das et al. (2025); Jackulin and Murugavalli (2022); Jelali et al. (2024).

Perkembangan *computer vision* dan *deep learning* telah membuka peluang untuk mengotomatisasi proses klasifikasi penyakit tanaman berbasis citra. Berbagai penelitian terbaru menunjukkan bahwa citra daun tomat dapat digunakan untuk membangun model klasifikasi penyakit dengan tingkat performa yang baik. Selain penelitian model, ketersediaan dataset publik juga semakin mendukung pengembangan riset pada domain ini,

termasuk dataset daun tomat multikelas dengan beberapa kategori penyakit dan daun sehat Imtiaz et al. (2025); Liu et al. (2025); Oni et al. (2025); Sun et al. (2024).

Meskipun demikian, kebutuhan implementasi sistem di lapangan tidak hanya menuntut model yang akurat, tetapi juga efisien ketika dijalankan pada perangkat dengan sumber daya komputasi terbatas. Dalam konteks tersebut, komputasi *edge* menjadi relevan karena proses inferensi dapat dilakukan secara lokal, lebih dekat dengan sumber data, sehingga berpotensi mengurangi latensi, menurunkan ketergantungan pada komputasi awan, serta meningkatkan respons sistem secara langsung Gill et al. (2025); Majeed et al. (2024); Singh and Gill (2023); Xu et al. (2025).

Seiring perkembangan model *deep learning*, keluarga YOLO terus berevolusi dan menjadi salah satu arsitektur yang banyak diperhatikan karena menawarkan keseimbangan antara kecepatan dan performa. Literatur ulasan terbaru menunjukkan bahwa perkembangan YOLO bergerak dari versi awal hingga versi yang lebih baru dengan penekanan pada efisiensi dan fleksibilitas penerapan Ali and Zhang (2024); Murat and Kiran (2025); Terven et al. (2023). Pada dokumentasi resmi Ultralytics, YOLOv8 dan YOLO11 juga mendukung tugas *image classification*, sehingga keduanya dapat digunakan untuk membandingkan performa klasifikasi penyakit daun tomat, bukan hanya untuk *object detection* Ultralytics (2026a,b,c).

Selain model, aspek akuisisi citra juga memengaruhi hasil klasifikasi. Variasi pencahayaan, sudut pengambilan, jarak kamera, latar belakang, dan kualitas visual daun dapat memengaruhi karakteristik citra yang diproses model. Oleh karena itu, dalam penelitian ini kamera tidak diposisikan sebagai variabel bebas, melainkan sebagai alat akuisisi data yang dikendalikan melalui kondisi pengambilan gambar yang dibuat konsisten. Dengan pendekatan tersebut, fokus penelitian tetap diarahkan pada perbandingan performa model, bukan pada perbedaan kualitas perangkat akuisisi.

Berdasarkan penelusuran awal literatur, penelitian mengenai penyakit daun tomat berbasis *deep learning* sudah cukup banyak dilakukan, tetapi perbandingan yang secara khusus menilai YOLOv8 Nano dan YOLO11 Nano untuk tugas klasifikasi pada perangkat *edge* masih terbatas. Padahal, perbandingan ini penting untuk mengetahui model mana yang lebih sesuai diterapkan pada perangkat dengan sumber daya terbatas. Dalam penelitian ini, perangkat *edge* yang digunakan adalah Raspberry Pi 5 dengan RAM 8 GB sebagai media implementasi dan pengujian model Raspberry Pi Ltd (2026a,b).

Berdasarkan uraian tersebut, penelitian ini mengangkat judul **Analisis Komparatif YOLOv8 Nano dan YOLO11 Nano dalam Klasifikasi Penyakit Daun Tomat berbasis Perangkat Edge**. Penelitian ini diharapkan dapat memberikan kontribusi dalam menentukan model yang lebih sesuai untuk kebutuhan klasifikasi penyakit daun tomat berbasis citra pada lingkungan komputasi terbatas, dengan mempertimbangkan dua aspek utama, yaitu akurasi klasifikasi dan efisiensi komputasi.

1.2 Permasalahan Penelitian

1.2.1 Identifikasi Masalah

1. Identifikasi penyakit daun tomat secara manual masih bergantung pada pengamatan visual manusia yang memerlukan pengalaman dan berpotensi menimbulkan ketidakkonsistenan hasil.
2. Pendekatan berbasis citra dan *deep learning* telah menunjukkan potensi untuk klasifikasi penyakit daun tomat, namun performa dan efisiensinya masih bergantung pada model yang digunakan.
3. Implementasi model klasifikasi pada perangkat *edge* memerlukan model yang tidak hanya akurat, tetapi juga efisien dari sisi waktu inferensi dan penggunaan sumber daya.

4. Hasil klasifikasi citra dapat dipengaruhi oleh variasi kondisi akuisisi gambar, seperti pencahayaan, sudut pengambilan, jarak kamera, dan latar belakang.
5. Belum banyak penelitian yang secara spesifik membandingkan YOLOv8 Nano dan YOLO11 Nano untuk klasifikasi penyakit daun tomat pada perangkat *edge*.

1.2.2 Batasan Masalah

Agar penelitian lebih terarah dan fokus, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian difokuskan pada tugas *image classification* untuk menentukan kelas penyakit daun tomat dari citra.
2. Model yang dibandingkan hanya dua, yaitu YOLOv8 Nano dan YOLO11 Nano.
3. Data masukan penelitian berupa citra daun tomat yang telah diberi label berdasarkan kelas penyakit yang digunakan pada dataset penelitian.
4. Pengujian implementasi model dilakukan pada perangkat *edge* berupa Raspberry Pi 5 dengan RAM 8 GB.
5. Akuisisi citra pada pengujian implementasi dilakukan dengan kondisi yang dijaga tetap agar pengaruh variasi kamera dan lingkungan tidak menjadi variabel utama penelitian.
6. Aspek yang dibandingkan dibatasi pada akurasi dan efisiensi model, dengan indikator seperti akurasi klasifikasi, *precision*, *recall*, *F1-score*, waktu inferensi, dan penggunaan sumber daya yang relevan.
7. Penelitian tidak membahas *object detection*, segmentasi, maupun rekomendasi penanganan penyakit tanaman, tetapi berfokus pada klasifikasi penyakit daun tomat berbasis citra.

1.2.3 Rumusan Masalah

Berdasarkan identifikasi masalah dan batasan masalah di atas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa YOLOv8 Nano dan YOLO11 Nano dalam melakukan klasifikasi penyakit daun tomat?
2. Bagaimana perbandingan akurasi YOLOv8 Nano dan YOLO11 Nano pada dataset klasifikasi penyakit daun tomat yang digunakan?
3. Bagaimana perbandingan efisiensi YOLOv8 Nano dan YOLO11 Nano ketika dijalankan pada perangkat *edge* berupa Raspberry Pi 5 8 GB?
4. Sejauh mana pengendalian kondisi akuisisi citra dapat mendukung objektivitas perbandingan performa kedua model?
5. Model manakah yang lebih sesuai untuk diterapkan pada sistem klasifikasi penyakit daun tomat berbasis perangkat *edge*?

1.3 Tujuan dan Manfaat Penelitian

1.3.1 Tujuan

Tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Menerapkan YOLOv8 Nano dan YOLO11 Nano untuk klasifikasi penyakit daun tomat berbasis citra.
2. Membandingkan akurasi kedua model pada data klasifikasi penyakit daun tomat.
3. Menganalisis efisiensi kedua model pada perangkat *edge* berupa Raspberry Pi 5 8 GB berdasarkan metrik pengujian yang digunakan.

4. Menerapkan skenario akuisisi citra yang terkontrol agar perbandingan model dilakukan pada kondisi data yang konsisten.
5. Menentukan model yang lebih optimal untuk implementasi klasifikasi penyakit daun tomat pada perangkat *edge*.

1.3.2 Manfaat

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Manfaat teoritis

Penelitian ini diharapkan dapat menambah referensi ilmiah mengenai penerapan *deep learning*, khususnya model keluarga YOLO, pada klasifikasi penyakit daun tomat berbasis citra serta memberikan gambaran mengenai hubungan antara akurasi model, efisiensi komputasi, dan implementasi pada perangkat *edge*.

2. Manfaat praktis

Penelitian ini diharapkan dapat menjadi bahan pertimbangan dalam pemilihan model yang tepat untuk pengembangan sistem klasifikasi penyakit daun tomat yang ringan, cepat, dan dapat dijalankan secara lokal pada perangkat dengan sumber daya terbatas.

3. Manfaat metodologis

Penelitian ini diharapkan dapat memberikan gambaran mengenai pentingnya pengendalian kondisi akuisisi citra, seperti pencahayaan, sudut pengambilan, jarak kamera, dan latar belakang, agar evaluasi model klasifikasi berbasis citra dapat dilakukan secara lebih adil dan objektif.

1.4 Sistematika Penulisan

BAB I PENDAHULUAN

Berisi latar belakang masalah, identifikasi masalah, batasan masalah, rumusan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan.

BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN

Menjelaskan teori-teori yang mendukung penelitian, meliputi konsep penyakit daun tomat, klasifikasi citra, *deep learning*, model YOLO, perangkat *edge*, akuisisi citra, penelitian terdahulu, dan kerangka pemikiran penelitian.

BAB III METODE PENELITIAN

Menjelaskan tahapan penelitian yang dilakukan, mulai dari pengumpulan data, penentuan kelas penyakit, skenario akuisisi citra, *preprocessing*, pelatihan model, implementasi pada perangkat *edge*, hingga pengujian dan evaluasi.

BAB IV HASIL DAN PEMBAHASAN

Menyajikan hasil pelatihan dan pengujian model, analisis perbandingan akurasi dan efisiensi, serta pembahasan hasil penelitian sesuai rumusan masalah.

BAB V KESIMPULAN DAN SARAN

Berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya.

BAB II

LANDASAN TEORI DAN KERANGKA PEMIKIRAN

2.1 Tinjauan Pustaka

Penelitian mengenai klasifikasi penyakit daun tomat berbasis citra telah berkembang seiring kemajuan *computer vision* dan *deep learning*. Berbagai penelitian terdahulu menunjukkan bahwa citra daun tomat dapat dimanfaatkan untuk mengenali kondisi sehat maupun beberapa jenis penyakit secara otomatis, baik menggunakan arsitektur CNN umum, model ringan, maupun pendekatan yang diarahkan untuk implementasi praktis di lapangan.

Kajian pada Jackulin and Murugavalli (2022) menunjukkan bahwa *machine learning* dan *deep learning* telah banyak diterapkan pada deteksi penyakit tanaman, termasuk melalui analisis citra daun. Kajian tersebut menegaskan bahwa pendekatan berbasis visi komputer mampu meningkatkan konsistensi identifikasi penyakit dibandingkan pengamatan manual. Namun, pembahasannya masih bersifat umum pada domain penyakit tanaman dan belum berfokus secara spesifik pada penyakit daun tomat maupun perangkat *edge*.

Kajian khusus pada tanaman tomat dalam Jelali et al. (2024) menunjukkan bahwa *deep learning* telah banyak digunakan untuk mendeteksi penyakit dan hama pada tanaman tomat dengan memanfaatkan dataset laboratorium maupun citra lapangan. Kajian ini penting karena menunjukkan bahwa tomat merupakan domain yang aktif diteliti dan relevan untuk pengembangan model berbasis citra. Akan tetapi, fokus utamanya masih mencakup berbagai arsitektur secara umum dan belum diarahkan pada perbandingan dua generasi model ringan YOLO untuk klasifikasi pada perangkat *edge*.

Ulasan pada Das et al. (2025) juga memperlihatkan bahwa teknik klasifikasi, deteksi, dan segmentasi berbasis *deep learning* telah memberikan kemajuan signifikan dalam identifikasi penyakit daun tomat. Ulasan tersebut menegaskan bahwa tantangan utama penelitian bukan hanya akurasi model, tetapi juga bagaimana model dapat diterapkan secara efektif pada kondisi nyata yang memiliki keterbatasan perangkat dan variasi lingkungan. Hal ini memperkuat relevansi penelitian yang tidak hanya menilai akurasi, tetapi juga efisiensi model.

Dari sisi data, beberapa dataset publik terbaru semakin memperkuat kelayakan penelitian pada domain ini. Dataset pada Imtiaz et al. (2025) menyediakan 731 citra resolusi tinggi daun tomat yang mencakup enam jenis penyakit umum serta daun sehat. Dataset pada Oni et al. (2025) memuat 1.028 citra daun tomat sehat dan bergejala yang diambil pada kondisi lapangan yang beragam. Selain itu, dataset pada Liu et al. (2025) menyediakan 1.026 citra penyakit tomat dari lingkungan rumah kaca modern dengan anotasi yang dikurasi untuk mendukung klasifikasi maupun deteksi. Ketersediaan dataset tersebut menunjukkan bahwa penelitian klasifikasi penyakit daun tomat dapat dilakukan dengan basis data yang cukup jelas dan terdokumentasi.

Pada sisi model, Sun et al. (2024) menunjukkan bahwa penggabungan strategi ekstraksi fitur dan pembelajaran mendalam dapat meningkatkan performa klasifikasi penyakit daun tomat. Meskipun demikian, penelitian tersebut tidak secara khusus membandingkan model keluarga YOLO varian *nano*. Penelitian pada Majeed et al. (2024) lebih dekat dengan konteks penelitian ini karena mengevaluasi solusi *edge AI* mandiri untuk penyakit tomat menggunakan jaringan ringan. Hasilnya menegaskan bahwa dalam implementasi lapangan, pemilihan model harus mempertimbangkan keseimbangan antara akurasi dan efisiensi inferensi.

Dalam konteks komputasi *edge*, Singh and Gill (2023), Gill et al. (2025), serta Xu et al. (2025) menjelaskan bahwa *edge AI* menjadi

pendekatan yang semakin penting karena mampu mendukung inferensi lokal dengan latensi lebih rendah dan ketergantungan yang lebih kecil terhadap komputasi awan. Hal ini menjadikan perangkat *edge* relevan untuk sistem klasifikasi penyakit tanaman yang ditujukan untuk membantu keputusan cepat di lapangan.

Sementara itu, perkembangan keluarga YOLO telah dibahas pada Terven et al. (2023), Ali and Zhang (2024), dan Murat and Kiran (2025). Ketiga referensi tersebut menunjukkan bahwa YOLO berkembang sebagai keluarga model yang menekankan keseimbangan antara kecepatan dan performa. Dokumentasi resmi Ultralytics juga menunjukkan bahwa YOLOv8 dan YOLO11 mendukung tugas *image classification*, sehingga keduanya relevan untuk dibandingkan pada penelitian ini Ultralytics (2026a,b,c).

Berdasarkan kajian terhadap penelitian terdahulu, dapat disimpulkan bahwa: (1) klasifikasi penyakit daun tomat berbasis citra telah terbukti layak dilakukan menggunakan *deep learning*; (2) ketersediaan dataset publik terbaru mendukung pelaksanaan penelitian secara lebih terukur; (3) isu efisiensi implementasi pada perangkat *edge* masih menjadi aspek penting yang belum selalu dibahas secara mendalam; dan (4) penelitian yang secara khusus membandingkan YOLOv8 Nano dan YOLO11 Nano untuk klasifikasi penyakit daun tomat pada perangkat *edge* masih relatif terbatas. Oleh karena itu, penelitian ini menempati posisi sebagai upaya untuk mengisi celah tersebut dengan membandingkan dua model ringan dari keluarga YOLO pada tugas klasifikasi citra dengan fokus pada akurasi dan efisiensi.

2.2 Landasan Teori

Landasan teori dalam penelitian ini digunakan untuk menjelaskan konsep-konsep utama yang berkaitan dengan penyakit daun tomat, klasifikasi citra, *deep learning*, keluarga YOLO, perangkat *edge*, dan akuisisi

citra. Teori-teori tersebut menjadi dasar dalam penyusunan metode penelitian serta analisis hasil yang diperoleh.

2.2.1 Penyakit Daun Tomat

Penyakit daun tomat merupakan gangguan pada daun tanaman tomat yang disebabkan oleh jamur, bakteri, virus, maupun faktor lain yang memunculkan gejala visual tertentu, seperti bercak, perubahan warna, nekrosis, dan deformasi. Identifikasi dini terhadap gejala pada daun penting dilakukan karena kondisi daun sering menjadi indikator awal adanya gangguan kesehatan tanaman yang dapat memengaruhi pertumbuhan dan hasil panen Das et al. (2025); Jelali et al. (2024); Nyawose et al. (2025).

Dalam konteks penelitian berbasis citra, gejala visual pada daun tomat dapat dipelajari sebagai pola yang mewakili kelas penyakit tertentu. Oleh karena itu, daun tomat menjadi objek yang sesuai untuk tugas klasifikasi citra, terutama ketika dataset telah menyediakan label kelas yang jelas dan proses akuisisi citra dilakukan secara memadai Imtiaz et al. (2025); Liu et al. (2025); Oni et al. (2025).

2.2.2 Klasifikasi Citra

Klasifikasi citra adalah proses pemberian label pada suatu citra berdasarkan karakteristik visual yang terkandung di dalamnya. Pada tugas ini, seluruh citra diperlakukan sebagai satu kesatuan masukan dan sistem menghasilkan satu label kelas sebagai keluaran. Dalam penelitian ini, label keluaran merepresentasikan jenis penyakit atau kondisi sehat pada daun tomat.

Berbeda dengan *object detection* yang bertujuan menemukan lokasi objek tertentu pada citra, klasifikasi citra lebih tepat digunakan ketika yang ingin ditentukan adalah kategori

keseluruhan gambar. Oleh karena itu, untuk kasus penelitian ini, pendekatan klasifikasi dipilih karena tujuan utamanya adalah menentukan kelas penyakit dari citra daun tomat secara keseluruhan, bukan mendeteksi posisi area penyakit pada daun Sun et al. (2024); Ultralytics (2026a).

2.2.3 *Deep Learning* dan CNN

Deep learning merupakan cabang dari *machine learning* yang menggunakan jaringan saraf tiruan berlapis untuk mempelajari pola yang kompleks dari data. Dalam bidang pengolahan citra, pendekatan ini banyak diterapkan karena mampu mengekstraksi fitur visual secara otomatis tanpa ketergantungan penuh pada rekayasa fitur manual Jackulin and Murugavalli (2022); Nyawose et al. (2025).

Salah satu arsitektur yang paling umum digunakan dalam klasifikasi citra adalah *Convolutional Neural Network* (CNN). CNN memanfaatkan operasi konvolusi untuk menangkap pola spasial pada citra, seperti tepi, tekstur, warna, dan bentuk, yang kemudian diproses lebih lanjut untuk menghasilkan keputusan klasifikasi. Dalam penelitian penyakit tanaman, CNN telah banyak digunakan karena efektif dalam mengenali gejala visual pada daun Das et al. (2025); Jelali et al. (2024); Sun et al. (2024).

2.2.4 Keluarga Model YOLO

YOLO (*You Only Look Once*) merupakan keluarga model *deep learning* yang awalnya dikenal luas pada tugas *object detection*. Perkembangannya dari versi awal hingga versi terbaru menunjukkan adanya peningkatan pada efisiensi, akurasi, dan fleksibilitas penggunaan Ali and Zhang (2024); Murat and Kiran (2025); Terven et al. (2023).

Varian modern dari keluarga YOLO tidak hanya digunakan untuk *object detection*, tetapi juga mendukung tugas lain, termasuk klasifikasi citra. Dokumentasi resmi Ultralytics menyebutkan bahwa image classification digunakan untuk mengelompokkan seluruh citra ke dalam kelas yang telah ditetapkan, dan dukungan tersebut tersedia pada ekosistem YOLOv8 maupun YOLO11 Ultralytics (2026a,b,c).

Dalam penelitian ini, dua model yang dibandingkan adalah YOLOv8 Nano dan YOLO11 Nano. Keduanya termasuk kategori model ringan (*nano*) yang dirancang untuk memberikan keseimbangan antara ukuran model, kecepatan inferensi, dan performa prediksi. Dengan karakteristik tersebut, kedua model dipandang relevan untuk diuji pada lingkungan komputasi terbatas seperti perangkat *edge*. Pemilihan keduanya juga didasarkan pada kebutuhan penelitian untuk membandingkan dua generasi model ringan dari keluarga yang sama, sehingga analisis dapat lebih terarah pada perbedaan performa antarversi model.

2.2.5 Perangkat *Edge*

Komputasi *edge* adalah pendekatan pemrosesan data yang dilakukan lebih dekat dengan sumber data atau lokasi tempat data dihasilkan. Pada pendekatan ini, inferensi model dapat dijalankan secara lokal tanpa selalu bergantung pada server pusat atau komputasi awan. Pendekatan tersebut memiliki beberapa keunggulan, seperti latensi yang lebih rendah, respons yang lebih cepat, dan potensi efisiensi komunikasi data Gill et al. (2025); Singh and Gill (2023); Xu et al. (2025).

Dalam penelitian ini, perangkat *edge* digunakan sebagai media implementasi untuk menguji efisiensi model klasifikasi. Raspberry Pi 5 dipilih sebagai perangkat pengujian karena

merupakan platform komputasi lokal yang mendukung CPU quad-core Arm Cortex-A76 2.4 GHz dan varian RAM hingga 16 GB, termasuk versi 8 GB yang digunakan dalam penelitian ini Raspberry Pi Ltd (2026a,b). Penggunaan perangkat *edge* penting karena penelitian ini tidak hanya bertujuan mengetahui model yang lebih akurat, tetapi juga model yang lebih layak diterapkan pada sistem nyata dengan keterbatasan sumber daya komputasi.

2.2.6 Akuisisi Citra dan Faktor Kamera

Pada sistem klasifikasi berbasis citra, kualitas data masukan sangat memengaruhi hasil klasifikasi. Faktor-faktor seperti resolusi gambar, pencahayaan, sudut pengambilan, jarak kamera terhadap objek, latar belakang, serta kestabilan posisi kamera dapat memengaruhi karakteristik visual citra yang diproses oleh model. Pada citra daun tomat, variasi tersebut dapat memengaruhi keterbacaan gejala penyakit, seperti bercak, perubahan warna, dan tekstur permukaan daun Imtiaz et al. (2025); Liu et al. (2025); Oni et al. (2025).

Dalam konteks penelitian ini, kamera tidak diposisikan sebagai variabel bebas, tetapi sebagai alat akuisisi citra yang harus dikendalikan. Hal ini berarti bahwa pengambilan citra perlu dilakukan pada kondisi yang dibuat konsisten agar pengaruh variasi kamera dan lingkungan dapat diminimalkan. Dengan pengendalian tersebut, perbandingan model dapat lebih objektif karena perbedaan hasil lebih mencerminkan performa model daripada variasi kualitas data akuisisi.

2.2.7 Akurasi dan Efisiensi sebagai Dasar Evaluasi

Akurasi dalam penelitian klasifikasi menunjukkan tingkat ketepatan model dalam memberikan label yang benar terhadap data uji. Selain akurasi, penelitian klasifikasi juga dapat

memanfaatkan metrik lain, seperti *precision*, *recall*, dan *F1-score*, untuk memberikan gambaran performa yang lebih komprehensif. Pada klasifikasi multikelas, metrik-metrik tersebut penting untuk menilai apakah model mampu membedakan antarpenyakit secara konsisten.

Efisiensi merupakan aspek penting dalam implementasi model pada perangkat *edge*. Efisiensi dapat dinilai melalui indikator seperti waktu inferensi, penggunaan memori, ukuran model, dan penggunaan sumber daya komputasi lain yang relevan. Dalam penelitian ini, akurasi dan efisiensi diposisikan sebagai dua dasar utama untuk menentukan model yang lebih sesuai diterapkan pada sistem klasifikasi penyakit daun tomat berbasis perangkat *edge* Gill et al. (2025); Majeed et al. (2024); Singh and Gill (2023); Xu et al. (2025).

2.3 Kerangka Pemikiran

Penelitian ini berangkat dari kebutuhan akan metode klasifikasi penyakit daun tomat yang lebih praktis, cepat, dan konsisten dibandingkan pendekatan identifikasi manual. Pendekatan berbasis citra dipilih karena memungkinkan gejala visual pada daun diproses menggunakan model *deep learning*. Berdasarkan kajian pustaka, penelitian penyakit daun tomat berbasis citra telah menunjukkan hasil yang baik, sedangkan keluarga YOLO berkembang sebagai model yang menekankan keseimbangan antara performa dan efisiensi Ali and Zhang (2024); Das et al. (2025); Jelali et al. (2024); Murat and Kiran (2025).

Penelitian ini kemudian memfokuskan perhatian pada dua model ringan, yaitu YOLOv8 Nano dan YOLO11 Nano, karena keduanya dipandang cocok untuk dibandingkan pada perangkat *edge*. Agar perbandingan dilakukan secara adil, citra daun tomat pada pengujian implementasi dikumpulkan dalam kondisi akuisisi yang dikendalikan

sehingga variasi pencahayaan, sudut pengambilan, jarak kamera, dan latar belakang dapat diminimalkan. Setelah itu, kedua model dilatih dan diuji menggunakan dataset yang sama, lalu hasilnya dibandingkan berdasarkan aspek akurasi dan efisiensi.

Secara garis besar, alur kerangka pemikiran dalam penelitian ini adalah sebagai berikut:

1. Penyakit daun tomat merupakan masalah penting yang dapat menurunkan kualitas dan hasil panen.
2. Pendekatan identifikasi manual memiliki keterbatasan dari sisi kecepatan, konsistensi, dan ketergantungan pada pengalaman pengamat.
3. Pendekatan berbasis citra dan *deep learning* memiliki potensi untuk mengklasifikasikan penyakit daun tomat secara otomatis.
4. Model klasifikasi yang diterapkan pada perangkat *edge* harus dinilai tidak hanya dari akurasi, tetapi juga dari efisiensinya.
5. YOLOv8 Nano dan YOLO11 Nano dipilih sebagai dua model ringan yang akan dibandingkan.
6. Pengujian dilakukan pada perangkat *edge* dengan data citra yang diperoleh melalui akuisisi terkontrol.
7. Hasil pengujian digunakan untuk menentukan model yang lebih sesuai untuk klasifikasi penyakit daun tomat pada perangkat *edge*.

Dengan kerangka pemikiran tersebut, penelitian ini diharapkan mampu memberikan dasar yang jelas dalam menjawab rumusan masalah sekaligus menunjukkan posisi penelitian ini di antara penelitian-penelitian terdahulu yang relevan.

2.4 Kerangka Pemikiran



Gambar 2.1
Kerangka Pemikiran

DAFTAR PUSTAKA

- Ali, M. L. and Zhang, Z. (2024). The yolo framework: A comprehensive review of evolution, applications, and benchmarks in object detection. *Computers*, 13(12):336.
- Das, A., Roy, S., Sarkar, R., Ghosh, K., and Kumar, M. (2025). Deep learning-based classification, detection, and segmentation techniques for tomato leaf diseases: A review. *Smart Agricultural Technology*, 11:100816.
- Gill, S. S. et al. (2025). Edge ai: A taxonomy, systematic review and future directions. *Cluster Computing*, 28(1):1–53.
- Imtiaz, A., Islam, M. R., et al. (2025). A dataset for multiclass disease detection and classification of tomato leaves. *Data in Brief*, 59:111596.
- Jackulin, C. and Murugavalli, S. (2022). A comprehensive review on detection of plant disease using machine learning and deep learning approaches. *Measurement: Sensors*, 24:100441.
- Jelali, M., Mzoughi, O., Ksibi, A., Mahjoub, M. A., and Bouallegue, R. (2024). Deep learning networks-based tomato disease and pest detection: A comprehensive review and future directions. *Frontiers in Plant Science*, 15:1493322.
- Liu, Y. et al. (2025). A labeled image dataset of common tomato diseases for classification and object detection. *Data in Brief*, 61:112060.
- Majeed, Y., Zhang, J., et al. (2024). Standalone edge ai-based solution for tomato diseases detection using lightweight deep learning networks. *Smart Agricultural Technology*, 9:100590.
- Murat, A. A. and Kiran, M. S. (2025). A comprehensive review on yolo versions for object detection. *Engineering Science and Technology, an International Journal*, 70:102161.
- Nyawose, T., Tarimo, C., Adebayo, A., and Ojo, S. (2025). A review on the detection of plant disease using machine learning and deep learning approaches. *Journal of Imaging*, 11(10):326.
- Oni, M. K. et al. (2025). A comprehensive dataset of tomato leaf images for disease recognition under diverse backgrounds and lighting conditions. *Data in Brief*, 57:111189.
- Raspberry Pi Ltd (2026a). Raspberry pi 5 product brief. Official product brief, published April 2026, accessed April 19, 2026.

- Raspberry Pi Ltd (2026b). Raspberry pi 5 product page. Official product page, accessed April 19, 2026.
- Singh, R. and Gill, S. S. (2023). Edge ai: A survey. *Internet of Things and Cyber-Physical Systems*, 3:71–92.
- Sun, Y. et al. (2024). Tomato leaf disease classification by combining deep feature extraction and classification optimization. *Applied Sciences*, 14(17):7472.
- Terven, J., Córdova-Esparza, D.-M., and Romero-González, J.-A. (2023). A comprehensive review of yolo architectures in computer vision: From yolov1 to yolov8 and yolo-nas. *Machine Learning and Knowledge Extraction*, 5(4):1680–1716.
- Ultralytics (2026a). Image classification - ultralytics yolo docs. Official documentation, accessed April 19, 2026.
- Ultralytics (2026b). Yolo11 - ultralytics yolo docs. Official documentation, accessed April 19, 2026.
- Ultralytics (2026c). Yolov8 - ultralytics yolo docs. Official documentation, accessed April 19, 2026.
- Xu, Y., Khan, T. M., Song, Y., and Meijering, E. (2025). Edge deep learning in computer vision and medical diagnostics: A comprehensive survey. *Artificial Intelligence Review*, 58(3):93.